```
Overpass Overpass Overpass [BoldFont = *-SemiBold ] Overpass [UprightFont = *-ExtraLight, BoldFont = *-Light ] Overpass [UprightFont = *-Light, BoldFont = *-Regular ]
```

REPRODUCTIBILITÉ EN APPRENTISSAGE AUTOMATIQUE



Reproductibilité en apprentissage automatique Lintroduction

—C'est quoi la reproductibilité?

C'EST QUOI LA REPRODUCTIBILITÉ?

La reproductibité est le principe qui dit qu'on ne peut tire de conclusions que d'un évienne bien déciri, qui est apparu plaseurs fois, prevoqué par des personnes différentes. Par contre, en apprentissage automatique, la reproductibilité correspond (surtout) soit à être capable de reproduire des résultats, soit d'obtenir des résultats similaires en réceivotant un

Être capable de répliquer les résultats d'un article d'un projet,

à partir du même jeu de données ou un jeu de données différent (mais proche),

en utilisant la **procédure d'entraînement** de l'article ou en utilisant notre procédure d'entrainement et en utilisant le **code** du projet.

les points clés c'est l'idée que si une idée a de bons résultats, on devrait être capable de la reprendre et de retrouver les mêmes résultats.

En ML, les idées c'est des algos et la reproductibilité devient juste d'être capable de s'assurer que les performances rapportées sont les mêmes.

 $70\,\%$ des chercheurs en science on échoué dans leur tentative de reproduire un article d'un autre chercheur

POURQUOI S'Y INTÉRESSER?

1. IBaley, 20167

50 % 1

50~% n'ont pas réussit à reproduire leurs propres expérimentations

L'informatique ne fait pas exception à cela malgré la simplicité (théorique) de réplication des résultats. Selon une étude, sur **255** articles, près de 40 % n'étaient pas réplicable [Raff, 2019].



MOTIVATION



Reproductibilité en apprentissage automatique LOK, mais comment?

Version des données & Étapes de prétraitement

VERSION DES DONNÉES & ÉTAPES DE PRETRAMENTES.

VIENT

Avec quelle version des données doit-on travailler?

Comment gérer facilement plusieurs versions des données?

Comment définir facilement les étapes de prétraitement des données?

Il nous faut des data pipelines, des tuyaux que nous pouvons facilement raccorder à nos modèles pour l'entrainement et la mise en production.

Il faut somewhat voir nos données comme du code et qu'à chaque fois qu'on fait du traitement sur notre data c'est comme modifier notre codebase et c'est impératif d'avoir une trace, par exemple ...

VERSION DES DONNÉES & ÉTAPES DE PRÉTRAITEMENT





Version des données & Étapes de prétraitement

Avec quelle version des données doit-on travailler?

Comment gérer facilement plusieurs versions des données?

Comment définir facilement les étapes de prétraitement des données?

Il nous faut des data pipelines, des tuyaux que nous pouvons facilement raccorder à nos modèles pour l'entrainement et la mise en production.

Il faut somewhat voir nos données comme du code et qu'à chaque fois qu'on fait du traitement sur notre data c'est comme modifier notre codebase et c'est impératif d'avoir une trace, par exemple ...





└─Version des données & Étapes de prétraitement

Avec quelle version des données doit-on travailler?

Comment gérer facilement plusieurs versions des données?

Comment définir facilement les étapes de prétraitement des données?

Il nous faut des data pipelines, des tuyaux que nous pouvons facilement raccorder à nos modèles pour l'entrainement et la mise en production.

Il faut somewhat voir nos données comme du code et qu'à chaque fois qu'on fait du traitement sur notre data c'est comme modifier notre codebase et c'est impératif d'avoir une trace, par exemple ...



CODE

Avec quelle version du code doit-on travailler?

Comment savoir **rapidement** qu'elle est la différence d'implémentation entre deux versions du modèle ? Comment gérer **facilement** les divergences d'expérimentations ?

Il nous faut un outil nous permettant de **visualiser** la différence entre des fichiers de code et nous permettant d'avoir **plusieurs** versions du code en même temps, par exemple ...



Avec quelle version du code doit-on travailler?

Comment savoir **rapidement** qu'elle est la différence d'implémentation entre deux versions du modèle ? Comment gérer **facilement** les divergences d'expérimentations ?

Il nous faut un outil nous permettant de **visualiser** la différence entre des fichiers de code et nous permettant d'avoir **plusieurs** versions du code en même temps, par exemple ...

CODE

Avec quelle version du code doit-on travailler?

Comment savoir **rapidement** qu'elle est la différence d'implémentation entre deux versions du modèle ? Comment gérer **facilement** les divergences d'expérimentations ?

Il nous faut un outil nous permettant de **visualiser** la différence entre des fichiers de code et nous permettant d'avoir **plusieurs** versions du code en même temps, par exemple ...

Reproductibilité en apprentissage automa └─OK, mais comment?	ıtique
Dépendances	

DÉPENDANCES



Avec quelle version de cette librairie doit-on travailler?

Comment gérer les conflits entre des versions?

Comment installer facilement et rapidement des dépendances?

Il nous faut un outil nous permettant de **définir** les dépendances, capable de gérer les conflits entre des versions et nous permettant d'installer facilement des dépendances.

Avec quelle version de cette librairie doit-on travailler?

Comment gérer les conflits entre des versions?

Comment installer facilement et rapidement des dépendances?

Il nous faut un outil nous permettant de **définir** les dépendances, capable de gérer les conflits entre des versions et nous permettant d'installer facilement des dépendances.

DÉDENDANCES

Avec quelle version de cette librairie doit-on travailler?

Comment gérer les conflits entre des versions?

Comment installer facilement et rapidement des dépendances?

Il nous faut un outil nous permettant de **définir** les dépendances, capable de gérer les conflits entre des versions et nous permettant d'installer facilement des dépendances.

-Environnement



Comment s'assurer que nos environnements de développement ne rentre pas en conflit entre eux?

Comment naviguer entre deux environnements?

Comment gérer plusieurs version des dépendances?

ENVIRONMEMENT

Comment s'assurer que nos environnements de développement ne rentre pas en conflit entre eux?

Comment naviguer entre deux environnements?

Comment gérer plusieurs version des dépendances?

ENVIRONMEMENT

Comment s'assurer que nos environnements de développement ne rentre pas en conflit entre eux?

Comment naviguer entre deux environnements?

Comment gérer plusieurs version des dépendances?

DÉVELOPPEMENT DES MODÈLES

Ne pas réinventer la roue.

2021-05-04

Simplifier l'écriture de code pour développer des modèles.

Qui facilite l'entrainement (GPU, multi-GPU/CPU).

Il nous faut des outils nous permettant de simplifier le développement de nos modèles, par exemple ...

Reproductibilité en apprentissage automatique LOK, mais comment ?
LDéveloppement
LDéveloppement des modèles

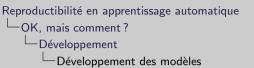
Ne pas réinventer la roue.

2021-05-04

Simplifier l'écriture de code pour développer des modèles.

Qui facilite l'entrainement (GPU, multi-GPU/CPU).

Il nous faut des outils nous permettant de simplifier le développement de nos modèles, par exemple ...





Ne pas réinventer la roue.

2021-05-04

Simplifier l'écriture de code pour développer des modèles.

Qui facilite l'entrainement (GPU, multi-GPU/CPU).

Il nous faut des outils nous permettant de simplifier le développement de nos modèles, par exemple ...

 $Avec \ quelle \ version \ du \ code, \ du \ mod\`ele \ et \ des \ donn\'ees \ avons-nous \ fait \ cet \ entrainement \ ?$

Quels sont les résultats?

2021-05-04

Comment visualiser rapidement les résultats et les paramètres de configuration ?

Avec quelle version du code, du modèle et des données avons-nous fait cet entrainement?

Quels sont les résultats?

Comment visualiser rapidement les résultats et les paramètres de configuration?

Avec quelle version du code, du modèle et des données avons-nous fait cet entrainement?

Quels sont les résultats?

Comment visualiser rapidement les résultats et les paramètres de configuration?

Avec quelle version du code, du modèle et des données avons-nous fait cet entrainement?

Quels sont les résultats?

2021-05-04

Comment visualiser rapidement les résultats et les paramètres de configuration?

Comment créer des tableaux de résultats facilement (pas à la mitaine)?

Comment s'assurer facilement que les résultats sont à jours?

Comment visualiser rapidement les résultats et les paramètres de configuration?

Il nous faut des outils nous permettant de **créer** des tableaux de résultats à **même les résultats**, soit de diminuer le plus possible le travail manuel, par exemple ...



Comment créer des tableaux de résultats facilement (pas à la mitaine)?

Comment s'assurer facilement que les résultats sont à jours?

Comment visualiser rapidement les résultats et les paramètres de configuration?

Il nous faut des outils nous permettant de **créer** des tableaux de résultats à **même les résultats**, soit de diminuer le plus possible le travail manuel, par exemple ...

2021-05-04

Comment créer des tableaux de résultats facilement (pas à la mitaine)?

Comment s'assurer facilement que les résultats sont à jours?

Comment visualiser rapidement les résultats et les paramètres de configuration?

Il nous faut des outils nous permettant de **créer** des tableaux de résultats à **même les résultats**, soit de diminuer le plus possible le travail manuel, par exemple ...

GESTION DES ENVIRONNEMENTS

Comment s'assurer que nos modèles fonctionnent sur d'autres environnements ? Comment faciliter la réutilisation de notre code ?





Comment s'assurer que nos modèles fonctionnent sur d'autres environnements ? Comment faciliter la réutilisation de notre code ? Développer des processus rigoureux (par essais, erreurs et journaux) et ne pas prendre tout ce qui a été discuté ici comme l'unique solution.

WEBINAIRE

MERCI DE VOTRE ÉCOUTE!